

AI Agent Platform

金融行业智能体平台

基于 RAG 检索增强生成与多 Agent 协作的金融智能投研平台

Next.js 14 全栈架构 • LangChain + LangGraph • PostgreSQL + Neo4j • Docker 微服务

项目类型	全栈 AI 应用平台（兼职项目）
技术领域	RAG / Agent / 知识图谱 / 金融 NLP
核心能力	智能问答 • 投研分析 • 合规审查 • 量化辅助
技术栈规模	前端 + 后端 + AI 编排 + 数据服务 + 9 容器编排
测试覆盖	325 / 333 通过（8 skip），L1-L4 测试金字塔
文档版本	2026.08

一、项目概述

本项目是一个面向金融行业的 AI 智能体平台，旨在解决传统金融信息服务中存在的三个核心痛点：一是海量研报、年报、公告等非结构化文档检索效率低下，关键数据散落在数百页 PDF 中难以快速定位；二是通用大语言模型在金融场景缺乏深度推理能力，对跨文档对比、指标计算、趋势分析等复杂问题支持不足；三是金融行业对合规性、可溯源性的严格要求，使得答案必须附带引用来源，且投资建议类问题需要合规拦截。

平台采用 Next.js 14 全栈架构构建，集成 LangChain + LangGraph 的 AI 编排能力，以 PostgreSQL 16 + pgvector + Neo4j 5 + Redis 7 为数据底座，通过 BGE-M3 + BGE-Reranker-v2-m3 (llama.cpp 本地部署) 与阿里百炼 DashScope 云端 LLM 的混合模型架构，实现 RAG 混合检索、多 Agent 协作、MCP 工具协议等核心能力，为金融投研、量化分析、合规审查等场景提供智能化解决方案。

核心解决的问题

- 非结构化文档检索：年报 PDF 动辄两三百页，关键财务数据散落在表格和附注中，传统关键词搜索召回率不足，需要语义检索 + 结构化提取双轨制方案。
- 复杂推理问题：跨公司对比、财务指标计算、同比趋势分析等需要多步推理和多文档关联，单一检索无法满足，需要 Agent 编排 + 知识图谱多跳推理。
- 合规与可溯源：金融场景要求答案必须标注引用来源，投资建议类问题需合规拦截，无法回答的问题需明确拒绝而非编造，需要严格的答案溯源和风控机制。
- 系统稳定性：LLM 服务存在额度限制和单点故障风险，需要多模型降级链、熔断器、语义缓存等多重保障确保服务可用性。

二、技术架构

项目采用前后端分离 + 微服务的架构设计，通过 Docker Compose 编排 9 个服务，包含 4 个应用服务（主应用、检索服务、评估服务、数据服务）和 5 个基础设施服务（PostgreSQL、Redis、Neo4j、Embedding 服务、Reranker 服务）。整体架构分为六层：用户界面层、API 层、Agent 层、RAG 管道层、MCP 工具层、数据层。

技术栈总览

层级	核心技术	说明
前端	Next.js 14 + React 18 + TypeScript + Tailwind CSS	App Router 架构, SSE 流式推送, Recharts 数据可视化
API 层	Route Handlers + FastAPI + NextAuth v5 + Zod	Next.js 原生路由 + Python 数据服务, JWT 认证, Zod 校验
AI 编排	LangChain 1.4 + LangGraph 1.3 + LlamaIndex 0.12	ReAct Agent + 反思循环 + 声明式 Skill 编排
LLM 服务	百炼 DashScope (云端) + BGE-M3 + BGE-Reranker-v2-m3 (本地)	多模型降级链, llama.cpp 本地部署 Embedding/Reranker
RAG 管道	pgvector + BM25 + RRF + GraphRAG + HyDE + 分离精排	混合检索 + 知识图谱多跳推理 + 查询改写
数据层	PostgreSQL 16 + pgvector + Drizzle ORM + Neo4j 5 + Redis 7	关系型 + 向量 + 图 + 缓存四库协同
Python 服务	FastAPI + baostock + efinance + mootdx + tushare	行情数据、财务数据、PDF 表格提取
任务队列	BullMQ + pg-ears (CDC 监听)	异步任务 + 数据库变更监听
容器化	Docker Compose (9 服务) + Nginx	一键编排, Nginx 反向代理
可观测性	Prometheus + Grafana	指标采集与监控告警
测试	Vitest (325 用例, L1-L4 金字塔)	单元 + 集成 + 端到端 + RAGAS 评估

架构分层说明

1. RAG 混合检索管道

采用四阶段检索架构：召回阶段使用稠密向量检索（pgvector）+ BM25 稀疏检索+ RRF 融合，兼顾语义相似性和关键词精确匹配；增强阶段引入 GraphRAG 知识图谱（Neo4j + 实体提取 + 三元组检索 + 多跳推理），发现文档间隐式关系；精排阶段采用分离精排策略（文档 chunk top5 + 图谱三元组 top3），避免短文本三元组挤掉长文本文档；查询优化阶段使用 HyDE 查询改写 + 金融领域同义词扩展，弥合用户 query 与文档表述的词汇鸿沟。

2. 多 Agent 协作层

基于 LangGraph 实现 ReAct + 反思循环的 Agent 架构，主 Agent（SimpleAgent）负责任务分解和工具调度，专业 Agent（Researcher 研究员 / Quant 量化分析师 / Compliance 合规官）处理垂直领域任务。通过声明式 Skill 技能层固化高频任务模式（技术分析、合规检查、风控评估、综合诊断），减少 LLM 决策负担。支持多工具链式调用（单轮解析多个工具调用），技术指标查询从 3 轮降到 2 轮，节省约 30% Token 消耗。

3. 双轨制查询路由（R001）

针对金融数值类问题检索失败的问题，设计五表双轨制架构：将财务数据从 PDF 结构化提取到 4 张标准化表（financial_income / balancesheet / cashflow / indicators）+ 1 张原始 JSON

表 (raw_tables)，通过指标清单驱动查询路由 (query-router) 实现数值类走 SQL 查询、非数值类走向量检索的智能分流。路由层包含意图识别 (数值/非数值)、公司名识别 (精确+模糊匹配)、指标识别 (正则匹配长别名优先)、模板 SQL 查询四个阶段，SQL 命中率达 90.9%。

4. 稳定性保障层

构建三状态熔断器 (closed → open → half-open, 3 次失败触发, 60 秒后半开) 防止 LLM 持续不可用时重试加剧压力; 304/403 额度耗尽立即强制熔断永久排除调度; temperature=0 + seed=42 确保金融分析结果一致性; LLM 语义缓存 (TTL 30 分钟, 最大 500 条) 减少重复调用; 基于 IP 的滑动窗口限流 (20 次/分钟) 保护百炼 API。多级降级策略: Reranker 失败→原始排序, 图谱失败→跳过, Redis 不可用→内存缓存。

三、核心功能 (已实现)

3.1 RAG 混合检索与答案溯源

- 向量检索 (BGE-M3, 8192 tokens 上下文) + BM25 稀疏检索 + RRF 融合, 兼顾语义与关键词匹配
- GraphRAG 知识图谱 (Neo4j) 支持跨文档实体关系推理和多跳查询
- HyDE 查询改写 + 金融领域同义词扩展, 提升 query 与文档的匹配度
- 分离精排: 文档 chunk top5 + 图谱三元组 top3, BGE-Reranker-v2-m3 精排
- 答案溯源: 引用注入 + 来源追踪, 每个答案标注文档来源和页码
- 智能切片: 800 字符 + 128 字符重叠 + 句子边界截断 + 多级断点优先级
- 文本清洗管线: 控制字符→空白规范→Markdown 噪声→页眉去重→全半角统一→Unicode NFC

3.2 多 Agent 协作与工具编排

- ReAct + 反思循环: 主 Agent 自主决策工具调用, 失败时反思重试
- 专业 Agent 分工: Researcher (投研) / Quant (量化) / Compliance (合规)
- MCP 工具协议: 21+ 金融工具统一注册表 (市场数据/量化分析/风控合规/RAG 检索)
- 声明式 Skill 编排: 技术分析、合规检查、风控评估等高频任务并行执行
- 多工具链式调用: 单轮解析多个工具调用, 减少迭代轮次
- 重复调用检测: toolCallHistory + duplicateCallCount, 连续 2 轮重复强制输出
- 数据真实性原则: 工具返回失败时拒绝编造, 强制检查结果成功性

3.3 财务数据结构化提取与双轨查询

- PDF 表格提取: pdfplumber 提取三张主表 (利润表/资产负债表/现金流量表), 结构化入库
- 五表双轨制: 4 张标准化表 + 1 张原始 JSON 表, 数值类走 SQL, 非数值类走向量检索
- 指标清单驱动路由: 意图识别 + 公司名识别 + 指标识别 + 模板 SQL, 命中率 90.9%
- 字段映射: 基于 indicator_aliases 别名词典, 支持长别名优先匹配
- 同比数据提取: 优先从财报「主要会计数据」表格提取权威同比值, 覆盖计算值

- 多数据源支持：PDF > Tushare > BaoStock 优先级，10 家评估样本公司数据完整入库

3.4 稳定性保障与多模型降级

- 多模型降级链：api_keys.yaml 驱动，列表顺序即优先级，自动切换
- 三状态熔断器：closed → open → half-open，3 次失败触发，60 秒后半开
- 强制熔断：304/403 额度耗尽立即永久排除，指数退避重试（1s → 2s → 4s）
- LLM 语义缓存：temperature=0 时启用，TTL 30 分钟，最大 500 条
- IP 滑动窗口限流：20 次/分钟，保护百炼 API QPS 限制
- 多级降级：Reranker 失败→原始排序，图谱失败→跳过，Redis 不可用→内存缓存
- HNSW → 顺序扫描降级：向量索引异常时自动降级，保证检索可用性

3.5 四层分层记忆系统

实现 L1 原始消息（完整对话历史）/ L2 滚动摘要（长对话压缩摘要）/ L3 历史检索（跨会话检索复用）/ L4 用户画像（偏好与行为特征）四层分层记忆，配合自适应 Token 预算策略，解决传统短记忆（20 条/6000 token 截断）在长对话和跨会话场景下上下文丢失的问题。

3.6 评估体系与质量保障

基于 RAGAS (Retrieval Augmented Generation Assessment) 思想自实现评估框架，覆盖 4 个核心指标（CP 上下文精确率 / CR 召回率 / F 忠实度 / AR 答案相关性）和 9 个任务分类（L1-L9），包含 150+ 评估样本。测试金字塔覆盖单元测试（325 用例）、集成测试、端到端测试和 RAGAS 评估四个层级，建立持续迭代的质量基线。

四、项目成果

项目经过多轮迭代优化，已建立完整的评估基线体系。以下为 RAGAS 评估的最新结果（V13-r4 轮次，基于 10 家上市公司年报数据评估）：

4.1 RAGAS 评估基线

评估指标	达标线	V13-r4 得分	状态	说明
综合得分	≥ 0.82	0.8688	达标	首次综合达标，较 V13-r3 提升 +0.0989
CP 上下文精确率	≥ 0.80	0.7273	接近	受 L3 计算推理类拖累（SQL 格式问题）
CR 上下文召回率	≥ 0.80	0.7242	接近	受 L4 同比数据格式问题影响
F 忠实度	≥ 0.85	0.9939	满分	LLM 完全忠实于检索上下文
AR 答案相关性	≥ 0.80	0.9345	达标	答案与问题高度相关

4.2 分类指标详情

任务分类	样本数	CP	CR	F	AR	诊断
L1 事实提取	30	0.93	0.93	1.00	0.96	全指标达标，数据质量修复生效
L2 跨文档对比	15	0.53	0.13	1.00	0.37	跨公司检索污染，待多实体并行检索
L3 计算推理	15	0.13	0.49	0.98	0.84	SQL JSON 格式对 CP 评估不友好
L4 趋势分析	10	1.00	0.45	1.00	1.00	CP/AR 满分，CR 受同比格式影响
L5 交易规则	15	0.80	0.69	0.97	0.88	接近达标
L6 技术指标	15	0.99	0.99	0.99	0.99	接近满分
L7 合规风控	10	0.73	0.45	0.98	0.55	合规答案相关性待优化
L8 对抗性	10	0.15	0.80	0.93	0.94	CP 评估逻辑问题
L9 无法回答	10	0.10	0.90	0.98	0.98	CP 评估逻辑问题

4.3 关键成果总结

- 综合得分首次达标：V13-r4 综合 0.8688 (≥ 0.82)，较 V12 提升 +0.30，较 V13-r3 提升 +0.10，验证双轨制查询路由方案有效性。
- L1 事实提取全指标达标：CP=CR=0.93，F=1.0，AR=0.96，财务数据质量修复（华海药业/中国能建/中国铁建/江苏银行）直接带动 CR 从 0.67 提升至 0.93。
- L6 技术指标接近满分：CP=CR=AR=0.99，技术指标查询路由和工具调用链路稳定。
- 忠实度满分：F=0.9939，LLM 完全忠实于检索上下文，无幻觉问题。
- 测试覆盖完整：325/333 测试通过（8 skip），CI/CD 4 流程全部通过。
- SQL 命中率 90.9%：55 条 L1/L3/L4 评估样本中 50 条命中 SQL 路由。

五、技术亮点与难点攻关

5.1 双轨制查询路由设计

传统 RAG 方案对金融数值类问题（如「中国铁建 2025 年营收是多少」）召回率不足，根因是 PDF 表格切片破坏了数值完整性，且向量检索对精确数值匹配能力弱。本项目设计五表双轨制方案：将财报 PDF 的三张主表结构化提取到 PostgreSQL 标准化表，通过指标清单驱动查询路由实现智能分流——命中标准化指标走 SQL 精确查询，未命中走向量检索 fallback。路由层包含意图识别、公司名识别（精确+别名+模糊匹配）、指标识别（正则匹配，长别名优先避免「净利润」误匹配「归属于母公司股东的净利润」）、模板 SQL 查询四个阶段。

5.2 PDF 财报表格结构化提取

年报 PDF 表格提取面临多重挑战：表头位置不固定（部分公司利润表标题在第 34 行而非前 5 行）、附注列干扰数据列对齐（「附注」列值如「七、51」被误当数值）、银行业报表字段映射差异（「利息净收入」vs「营业收入」）、部分 PDF 数值不在文本层（需 OCR fallback）。本项目通过全页扫描 fallback 定位偏离表头、小整数列检测识别纯整数附注、银行业字段映射特殊处理、长别名优先匹配等策略，实现 9/10 家评估样本公司数据完整入库。

5.3 GraphRAG 知识图谱多跳推理

向量检索无法发现文档间的隐式关系（如「A 公司是 B 公司的供应商」），本项目引入 GraphRAG：通过 LLM 实体提取构建 Neo4j 知识图谱，检索时进行三元组检索 + 多跳推理，发现跨文档关联。采用分离精排策略（文档 chunk top5 + 图谱三元组 top3），避免短文本三元组挤掉长文本文档导致检索质量下降。精排前按分数降序取 top5 限流，过滤噪声三元组。

5.4 评估数据集质量治理

评估数据集（qa-golden.json）的质量直接决定评估结果可信度。本项目发现并修复了三类系统性风险：一是 ground-truth 数据错误（如将「海外营收同比」误当「总营收同比」），二是评估标准过严（query 只问同比但 expectedAnswer 额外包含数值），三是 originalText 不聚焦（包含多个无关指标导致校验误报）。通过三源交叉验证（PDF 表格 + 数据库 + 手工计算）修正 ground-truth，建立 check_ground_truth.py 评估前必跑校验脚本，确保评估数据集可靠性。

5.5 多模型降级链与熔断保障

LLM 服务存在额度限制和单点故障风险。本项目设计多模型降级链（api_keys.yaml 驱动，列表顺序即优先级），配合三状态熔断器（closed → open → half-open）和强制熔断（304/403 额度耗尽立即永久排除），确保服务可用性。指数退避重试（1s → 2s → 4s）避免服务恢复初期压力集中，LLM 语义缓存（temperature=0 时启用）减少重复调用 Token 消耗。

六、规划升级路线图

项目当前已完成核心功能开发并建立评估基线，后续将围绕「提升评估全指标达标」和「扩展业务能力」两个方向持续迭代。以下为规划中的升级内容，部分已进入实施阶段：

6.1 近期升级（进行中）

升级项	目标	当前状态	预期效果
评估数据集质量治理	修正 ground_truth 错误，建立生成规范	已完成校验，0 个问题	评估结果可信度提升，可扩展到更多公司
PDF OCR fallback 链路	图片型 PDF 数值提取（PyMuPDF + PaddleOCR）	实施中	中国人保等图片型 PDF 数据完整入库
财报同比数据智能提取	优先从「主要会计数据」表格提取权威同比值	已完成，验证通过	同比数据准确率提升，减少计算误差
L3 计算推理 CP 优化	SQL JSON context 转自然语言描述	规划中	CP 从 0.13 提升至 0.80+
L4 趋势分析 CR 优化	同比数据格式标准化	规划中	CR 从 0.45 提升至 0.85+

6.2 中期升级（规划中）

- 多实体并行检索（R003）：针对 L2 跨文档对比问题（一次检索召回混合数据），调研同进程多线程隔离检索可行性，实现多公司独立检索后合并对比，预期 L2 CR 从 0.13 提升至 0.80+。
- 统一拒绝话语（R002）：合规拒绝与库外拒绝话语标准化，合规拒绝「受政策法规影响无法回答」，库外拒绝「知识储备不足」，语气委婉，提升用户体验和评估一致性。
- V14 官方评估库对接（R006）：对接 RAGAS 官方评估库，与自实现评估器交叉验证，评估 embedding 违规配置修复后的效果。
- 全公司数据扩展：从 10 家评估样本扩展到全 A 股上市公司，建立全量财务指标数据库，支持任意公司查询。
- 查询标准化改写：用户 query 中财务指标表述不统一问题，通过 query 改写标准化指标名（如「营收」→「营业收入」）。

6.3 远期规划

- 多模态 RAG：支持图表、K 线图、财报附图等多模态内容理解与检索，Vision 模型作为 OCR 最终 fallback。
- Agentic RAG 自适应检索：根据查询复杂度自适应调整检索深度和策略，简单问题快速返回，复杂问题深度检索 + 多轮推理。
- 增量索引与知识过期：按文档类型自动过期（研报 90 天/年报 365 天/法规永不过期），确保金融数据时效性。
- 流式 RAG：增量索引 + 流式检索结果推送，提升长查询用户体验。
- 用户画像与个性化：基于 L4 记忆层构建用户偏好画像，个性化推荐投研内容和分析视角。
- 权限与审计：企业级 RBAC 权限控制 + 操作审计日志，满足金融机构合规要求。

迭代方法论：项目采用 SSD（Spec-Design-Task）+ TDD 开发流程，三层文档体系（spec.md
全局约束 / design.md 架构设计 / task.md

任务验收)配合版本化管理和变更归档五步法(proposal → design → tasks → 实施 → 归档),确保文档与代码同步,功能完成度可验证。每轮迭代遵循「代码改动 → 端到端测试 → RAGAS 评估」闭环,测试不通过则停止迭代周期。